hw_ 3

Основы математической статистики. Количественные характеристики популяции. Графическое представление данных

In [ ]:

```

```

Задача 1

Даны значения зарплат из выборки выпускников:

```
100, 80, 75, 77, 89, 33, 45, 25, 65, 17, 30, 230, 24, 57, 55, 70, 75, 65, 84, 9
0, 150
```

Используя только встроенные питоновские функции и структуры данных (т.е. без библиотек `numpy`, `pandas` и др.), посчитайте (несмещённое) среднее квадратичное отклонение для данной выборки.

Решение:

Среднее квадратическое отклонение:

$$\sigma_X = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}\left(x_i - \overline{X}\right)^2}$$

In [14]:

```
n_array = [100, 80, 75, 77, 89, 33, 45, 25, 65, 17, 30, 230, 24, 57, 55, 70, 75, 65, 84
, 90, 150]
```

In [22]:

```
# Выборочное среднее X:
X = sum(n_array) / len(n_array)
print(f'Выборочное среднее X: {X}')
```

```
Выборочное среднее X: 73.14285714285714
```

In [20]:

```
# Выборочная дисперсия D:
def get_variance(array):
    sum_ = 0
    X_ = sum(array) / len(array)
    for x in array:
        sum_ += (x - X_)**2
    variance = sum_ / (len(array) - 1)
    return variance
```

In [23]:

```
print(f'Выборочная дисперсия D: {get_variance(n_array)}')
```

```
Выборочная дисперсия D: 2241.8285714285716
```

In [24]:

```
print(f'Среднее квадратическое отклонение: {get_variance(n_array)**0.5}')
```

```
Среднее квадратическое отклонение: 47.34795213553139
```

In [32]:

```
# Проверим средствами питру
import numpy as np
print(f'Выборочное среднее X: {np.mean(n_array)}')
print(f'Выборочная дисперсия D: {np.var(n_array, ddof=1)}')
print(f'Среднее квадратическое отклонение: {(np.std(n_array, ddof=1))}')
```

```
Выборочное среднее X: 73.14285714285714
Выборочная дисперсия D: 2241.828571428571
Среднее квадратическое отклонение: 47.347952135531386
```

Задача 2

Найдите число выбросов в выборке из задачи 1. Для определения выбросов используйте методику как при построении "усов" в `boxplot` , однако, как и в задаче 1, пользоваться можно только встроенными функциями и структурами данных.

Решение:

"Как при построении усов" - стало быть надо посчитать количество элементов "выпавших" за пределы диапазона

$$[Q_1 - 1.5 \times IQR,\ Q_3 + 1.5 \times IQR]\,,$$

где $Q_1 Q_3$ — первый и третий квантиль.
IQR — интерквартильное расстояние.

In [34]:

```
def quantil(l, number):
    ''' Расчет квантиля'''

    l = sorted(l)
    n = len(l)

    n_left_elements = int(n * number)
    n_right_elements = int(n * (1 - number))

    print(n, n_left_elements, n_right_elements)

    if n_left_elements + n_right_elements == n:
        return (l[n_left_elements - 1] + l[n_left_elements]) / 2

    else:
        assert n_left_elements + n_right_elements == n - 1

        return l[n_left_elements]
```

In [35]:

```
n_array = [100, 80, 75, 77, 89, 33, 45, 25, 65, 17, 30, 230, 24, 57, 55, 70, 75, 65, 84
, 90, 150]
```

In [41]:

```
# Первый квартиль — это квантиль 0.25 :
Q_1 = quantil(n_array, 0.25)
print(Q_1)
```

```
21 5 15
45
```

In [40]:

```
# Третий квартиль — это квантиль 0.75 :
Q_3 = quantil(n_array, 0.75)
print(Q_3)
```

```
21 15 5
84
```

In [45]:

```
# Интерквартильное расстояние:
IQD = Q_3 - Q_1
IQD
```

Out[45]:

```
39
```

In [50]:

```
# Границы интервала:
left_border = Q_1 - 1.5 * IQD
right_border = Q_3 + 1.5 * IQD
print(left_border)
print(right_border)
```

```
-13.5
142.5
```

In [68]:

```
# Найдем количество элементов из n_array, которые "вывалились" за эти границы:
out_range = [x for x in n_array if x <= left_border or x >= right_border]

print(f'ОТВЕТ')
print(f'Число выбросов в выборке равно {len(out_range)}')
print(f'"Вывалились" значения {out_range}')
```

```
ОТВЕТ
Число выбросов в выборке равно 2
"Вывалились" значения [230, 150]
```

In [57]:

```
import seaborn as sb
```

In [58]:

```
sb.boxplot(data=n_array)
```

Out[58]:

```
<AxesSubplot:>
```

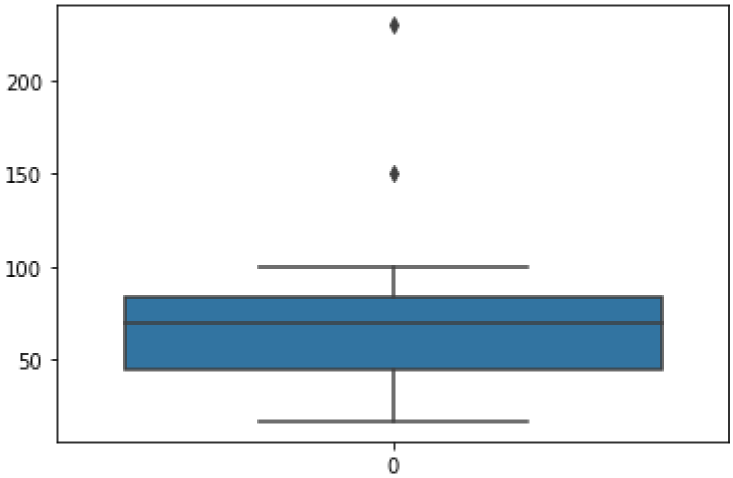

Задача 3

В университет на факультет A поступило 100 человек, на факультет B - 90 человек и на факультет C - 45 человек. Вероятность того, что студент с факультета A сдаст первую сессию, равна 0.6. Для студента с факультета B эта вероятность равна 0.7, а для студента с факультета C - 0.8. Случайным образом выбирается студент, сдавший первую сессию. Какое событие наиболее вероятно:

1. студент учится на факультете A,
2. студент учится на факультете B,
3. студент учится на факультете C?

Замечание: да, эта задача не на тему статистики, но тема важная, и её стоит иногда освежать в памяти.

Решение:

Это задача как раз для формулы Байеса:

$$P(F|H) = \frac{P(H|F) \cdot P(F)}{P(H)}$$

События F - чел был с факультета (A,B,C)
Гипотеза: H - чел сдал

По условию у нас уже есть:
$P(H|A) = 0.6$
$P(H|B) = 0.7$
$P(H|C) = 0.8$

In [71]:

```
P_HA = 0.6
P_HB = 0.7
P_HC = 0.8
```

In [72]:

```
# НАйдем P(F):
P_A = 100 / (100 + 90 + 45)
P_B = 90 / (100 + 90 + 45)
P_C = 45 / (100 + 90 + 45)
```

$P(H)$ найдем по формуле полной вероятности:

$$P(H) = P(H|A) \cdot P(A) + P(H|B) \cdot P(B) + P(H|C) \cdot P(C)$$

In [75]:

```
P_H = P_HA * P_A + P_HB * P_B + P_HC * P_C
P_H
```

Out[75]:

```
0.676595744680851
```

In [77]:

```
# Для факультета А формулы Байеса:
P_ah = P_HA * P_A / P_H
P_ah
```

Out[77]:

```
0.37735849056603776
```

In [79]:

```
# Для факультета В формулы Байеса:
P_bh = P_HB * P_B / P_H
P_bh
```

Out[79]:

```
0.39622641509433965
```

In [80]:

```
# Для факультета А формулы Байеса:
P_ch = P_HC * P_C / P_H
P_ch
```

Out[80]:

```
0.22641509433962265
```

ОТВЕТ:наиболее вероятно, что студент учится на факультете В

In [ ]:

```

```